

Model evaluated	Alternate Evaluator	Reproduction			Original		
		Agreement	Precision	Recall	Agreement	Precision	Recall
Claude	Llama-70B	0.78	0.72	0.94	0.84	0.84	0.97
DeepSeek	Llama-70B	0.88	0.91	0.95	0.82	0.80	0.95
GPT-4o	Llama-70B	0.89	0.91	0.96	0.89	0.90	0.98
GPT-5	Llama-70B	0.87	0.92	0.93	0.79	0.78	0.95
Gemini	Llama-70B	0.83	0.87	0.86	0.72	0.68	0.90
Llama-17B	Llama-70B	0.85	0.86	0.97	0.87	0.88	0.98
Llama-70B	Llama-70B	0.85	0.86	0.96	0.85	0.85	0.98
Llama-8B	Llama-70B	0.84	0.85	0.98	0.86	0.87	0.98
Mistral-24B	Llama-70B	0.89	0.90	0.98	0.87	0.87	0.98
Mistral-7B	Llama-70B	0.89	0.89	0.98	0.84	0.84	0.98
Qwen	Llama-70B	0.90	0.91	0.99	0.89	0.89	0.99