

Model evaluated	Alternate Evaluator	Agreement	Precision	Recall
Claude	Llama-70b	0.84	0.84	0.97
DeepSeek	Llama-70b	0.82	0.80	0.95
GPT-4o	Llama-70b	0.89	0.90	0.98
GPT-5	Llama-70b	0.79	0.78	0.95
Gemini	Llama-70b	0.72	0.68	0.90
Llama-17B	Llama-70b	0.87	0.88	0.98
Llama-70B	Llama-70b	0.85	0.85	0.98
Llama-8B	Llama-70b	0.86	0.87	0.98
Mistral-24B	Llama-70b	0.87	0.87	0.98
Mistral-7B	Llama-70b	0.84	0.84	0.98
Qwen	Llama-70b	0.89	0.89	0.99