

Model evaluated	Alternate Evaluator	Agreement	Precision	Recall
Claude	Llama-70B	0.78	0.72	0.94
DeepSeek	Llama-70B	0.88	0.91	0.95
GPT-4o	Llama-70B	0.89	0.91	0.96
GPT-5	Llama-70B	0.87	0.92	0.93
Gemini	Llama-70B	0.83	0.87	0.86
Llama-17B	Llama-70B	0.85	0.86	0.97
Llama-70B	Llama-70B	0.85	0.86	0.96
Llama-8B	Llama-70B	0.84	0.85	0.98
Mistral-24B	Llama-70B	0.89	0.90	0.98
Mistral-7B	Llama-70B	0.89	0.89	0.98
Qwen	Llama-70B	0.90	0.91	0.99