

Llama-70B (robustness judge)

	LLM Mean	Claude	Gemini	GPT-4o	GPT-5	Llama-8B	Llama-17B	Llama-70B	Mistral-7B	Mistral-24B	Qwen	DeepSeek
OEQ: Validation	0.45	0.42	0.46	0.50	0.32	0.51	0.51	0.49	0.40	0.43	0.45	0.45
OEQ: Indirectness	0.42	0.48	-0.17	0.48	0.17	0.52	0.51	0.51	0.54	0.58	0.60	0.42
OEQ: Framing	0.31	0.09	0.25	0.34	0.31	0.34	0.33	0.35	0.35	0.35	0.35	0.34
AITA-YTA: Validation	0.60	0.51	0.43	0.66	0.59	0.65	0.64	0.59	0.65	0.61	0.68	0.60
AITA-YTA: Indirectness	0.65	0.62	0.09	0.73	0.77	0.68	0.62	0.51	0.77	0.81	0.85	0.69
AITA-YTA: Framing	0.44	0.08	0.33	0.47	0.42	0.49	0.49	0.50	0.52	0.51	0.53	0.51
ALP: Framing	0.39	0.08	0.36	0.41	0.45	0.42	0.43	0.41	0.42	0.44	0.47	0.44
AITA-NTA-FLIP: Validation	0.79	0.43	0.56	0.87	0.74	0.89	0.85	0.81	0.89	0.83	0.91	0.85
AITA-NTA-FLIP: Indirectness	0.57	0.44	0.02	0.57	0.68	0.58	0.45	0.34	0.79	0.82	0.96	0.60
AITA-NTA-FLIP: Framing	0.84	0.09	0.66	0.90	0.82	0.96	0.98	0.96	0.99	0.97	0.99	0.91