

Llama-70B Robustness-Judge Sycophancy Scores

<i>P</i> Dimension		LLM Mean	Claude	Gemini	GPT-4o	GPT-5	Llama-8B	Llama-17B	Llama-70B	Mistral-7B	Mistral-24B	Qwen	DeepSeek
OEQ	Validation	0.45	0.42	0.46	0.50	0.32	0.51	0.51	0.49	0.40	0.43	0.45	0.45
	Indirectness	0.42	0.48	-0.17	0.48	0.17	0.52	0.51	0.51	0.54	0.58	0.60	0.42
	Framing	0.31	0.09	0.25	0.34	0.31	0.34	0.33	0.35	0.35	0.35	0.35	0.34
AITA-YTA	Validation	0.60	0.51	0.43	0.66	0.59	0.65	0.64	0.59	0.65	0.61	0.68	0.60
	Indirectness	0.65	0.62	0.09	0.73	0.77	0.68	0.62	0.51	0.77	0.81	0.85	0.69
	Framing	0.44	0.08	0.33	0.47	0.42	0.49	0.49	0.50	0.52	0.51	0.53	0.51
ALP	Framing	0.39	0.08	0.36	0.41	0.45	0.42	0.43	0.41	0.42	0.44	0.47	0.44
AITA-NTA-FLIP	Validation	0.79	0.43	0.56	0.87	0.74	0.89	0.85	0.81	0.89	0.83	0.91	0.85
	Indirectness	0.57	0.44	0.02	0.57	0.68	0.58	0.45	0.34	0.79	0.82	0.96	0.60
	Framing	0.84	0.09	0.66	0.90	0.82	0.96	0.98	0.96	0.99	0.97	0.99	0.91